傅申

(+86) 157-7969-2697 fushen@mail.ustc.edu.cn Fr4nk1inCs

教育经历

中国科学技术大学，计算机科学与技术专业，计算机系统结构方向，硕博连读 2024.09 – 至今

- GPA: 4.13/4.30 导师：李诚教授
- 课程：形式语言与计算复杂性 100，算法设计与分析 98，组合数学 97，高级计算机体系结构 96

中国科学技术大学，少年班学院，计算机科学与技术专业，本科 2020.09 – 2024.06

- GPA: 3.92/4.30 (前 8%)
- 课程：代数结构 98，人工智能基础 97，编译原理与技术 96，算法基础 94

研究经历

DeaMoE：面向快速小 Batch 解码的高效 MoE 架构开发与实现 2025.12 – 2026.01

- 针对 MoE 模型在小 Batch 解码场景下的内存受限瓶颈，参与设计并实现了一种基于专家分组共享参数的新型架构 DeaMoE，在保持模型精度的前提下，将每步推理的专家权重加载量最高降低 50.9%
- 负责 DeaMoE 架构在训练框架 Megatron-LM 和推理框架 vLLM 中的适配，开发了针对两阶段路由（Two-stage Routing）策略的定制化推理算子，在 A40 和 H100 显卡上实现了与权重加载量降低成正比的解码速度提升

动态 Top-K 路由 MoE 模型推理并行策略自动搜索 2025.05 – 2025.08

- 对于采用动态 Top-K 路由的 MoE 模型，针对其不同层之间计算开销存在的差异，设计并实现了一种并行策略自动搜索方法，将 Prefill-Only 任务和 Prefill 密集型任务的推理吞吐量分别提升至多 31% 和 16%
- 负责动态 Top-K 路由在 SGLang 中的适配与实现，参与了模型延迟分析器的实现、并行策略搜索算法的设计以及实验评估工作
- 相关论文已被 AAAI 2026 接收

论文发表

[1] Zewen Jin, **Shen Fu**, Chengjie Tang, Youhui Bai, Shengnan Wang, Jiaan Zhu, Chizheng Fang, Ping Gong, and Cheng Li. 2026. SMIDT: High-Performance Inference Framework for MoE Models with Dynamic Top-K Routing. *Proceedings of the AAAI Conference on Artificial Intelligence* 40, 27 (March 2026), 22444–22453. https://doi.org/10.1609/aaai.v40i27.39403

所获奖项

- 2023 年度蔷薇远志奖学金
- 2022 年度江淮蔚来汽车奖学金
- 2021 年度陈林义奖学金

其他经历

- 开源贡献：**sgl-project/sglang PR #6121**（为 Qwen 2/3 MoE 模型添加 DP Attention 支持）
- USENIX ATC '25 Artifact Evaluation Committee 成员
- 中国科学技术大学 2023 秋季学期编译原理与技术课程助教

专业技能

- **编程语言**：Python、C/C++、Lua、Shell
- **框架**：PyTorch、SGLang、Megatron-LM、vLLM